

Data Product Canvas

Problema 1 ¿Cuál es el problema? ¿Por qué es un problema? ¿Por qué?, ¿Por qué?, ¿Por qué? Los compradores de vivienda propia en Lima no tienen forma de saber si un inmueble está bien valorado, cómo es realmente su entorno (seguridad, calidad urbana), ni qué tan confiable es la constructora detrás del proyecto. Es la decisión financiera más grande de su vida y la toman con información incompleta: solo ven precio y fotos. ¿Por qué no saben si el precio es justo? → Porque ningún portal (Urbania, Properati) muestra un precio de referencia de mercado. ¿Por qué no saben del entorno real? → Porque la información de seguridad y calidad urbana no está integrada al listado. ¿Por qué compran en riesgo con constructoras? → Porque no existe un historial público consolidado de cumplimiento de plazos.	Data 3 Necesitamos entender sobre la data : ¿Qué data tienes interna y externa?, ¿Cuál puedes recolectar?, ¿qué data nueva puedes crear de manera simple? Data interna: - Dataset de criminalidad por zona. Data externa a recolectar: - Imágenes de entorno urbano. - Listados inmobiliarios (scraping Urbania/Properati): precio, área, distrito, habitaciones, piso, antigüedad, constructora, etapa del proyecto. - Puntos de interés (OpenStreetMap – Overpass API): colegios, parques, transporte, comercio, geolocalizados. - Registros públicos de constructoras: proyectos entregados/en curso, cuando estén disponibles. Data nueva: - constructora_reliability_score (agregando manualmente reclamos/noticias si no hay fuente estructurada). - Distancias geoespaciales calculadas (Haversine) entre cada inmueble y su POI más cercano. 4	Solución 5 ¿Cómo será la solución? ¿Cuál es el output esperado? Brainstorming Visualización geoespacial estática que cruza criminalidad y precio por zona. Sistema que identifica inmuebles subvalorados, evalúa su entorno con visión por computadora, y genera un ranking distinto para cada usuario según su perfil financiero y de estilo de vida, explicando el "por qué" de cada recomendación. Asistente conversacional que responde preguntas sobre zonas y precios usando un LLM. Solución priorizada Sistema de recomendación híbrido compuesto por tres modelos de Machine Learning que trabajan en conjunto: - Motor de valoración: Área, distrito, habitaciones, piso, antigüedad + variables de entorno. <u>Output</u>: predicted_price_soles → opportunity_score (qué tan por debajo de su valor real está listado). - Modelo de visión de entorno: Imágenes propias de zonas de Lima. <u>Output</u>: visual_quality_score: densidad urbana, presencia de áreas verdes, estado de infraestructura - Motor de recomendación personalizado: opportunity_score + zone_composite_index (seguridad + conveniencia + visual_quality_score) + constructora_reliability_score + perfil del usuario (pesos financieros y de estilo de vida). <u>Output</u>: Ranking final de propiedades, distinto por usuario, con explicación en lenguaje natural. ¿Cuál es el tipo de modelo? (Descriptivo, Predictivo, Prescriptivo) Es un sistema híbrido: predictivo (valoración de precio y calidad visual) + prescriptivo (la recomendación final ponderada según el perfil del usuario).	Actores 6 ¿Quiénes son tus stakeholders? ¿Quién es el sponsor? Stakeholders: Compradores de vivienda (usuario final). Constructoras/inmobiliarias confiables (beneficiarias indirectas — posible expansión B2B). Equipo del curso: Denzel (Cloud & DevOps), Jyns (ML Engineer), Lisseth (Data Analyst), Mafer (Full-Stack & UX/UI). Sponsor: Prof. Germain Garcia-Zanabria / Curso DS3022 (contexto académico); en un escenario real, una fintech o inmobiliaria interesada en diferenciarse por transparencia. 7	Impacto 8 ¿Cuál es el impacto? ¿Dónde se va a ver la mejora/Performance? Reducir de días a minutos el tiempo que toma comparar propiedades de forma informada, y dar visibilidad a constructoras confiables frente a las informales. La mejora se ve en la calidad de la decisión de compra del usuario (menos arrepentimiento post-compra) y en la reducción del gap entre precio pagado y precio justo de mercado.
Usuario 2 ¿Quiénes tienen este problema? ¿A quiénes va a impactar? Personas naturales (25-45 años aprox.) buscando comprar su primera vivienda o cambiar de vivienda en Lima Metropolitana, con capacidad de acceder a crédito hipotecario o ahorro propio. Compradores directos (usuario principal); indirectamente, constructoras e inmobiliarias confiables que hoy no tienen forma de diferenciarse de las informales.	Hipótesis 4 ¿Cuáles son las posibles causas del problema? - El mercado inmobiliario digital está fragmentado entre portales que no cruzan información. - No existe un actor (público o privado) que consolide precio + entorno + reputación en un solo lugar. - La asimetría de información favorece al vendedor/constructora, no al comprador.		Métricas claves 7 ¿Cuáles serían las métricas que deberíamos usar? - MAE (Mean Absolute Error) del predicted_price_soles vs. precio real de venta en transacciones históricas — mide el motor de valoración. % de concordancia entre el ranking del modelo y el orden de preferencia real que un usuario piloto asignaría manualmente — mide el motor de recomendación. - Accuracy/F1 del modelo de visión vs. etiquetas de validación manual de un subconjunto de imágenes — mide el modelo de visión. - Tiempo promedio de decisión del usuario (encuesta piloto) comparado con el proceso manual actual.	Acciones 9 ¿Cuáles son los siguientes pasos? ¿Qué acciones se realizarán? - Confirmar y documentar formalmente los datasets propios (criminalidad, imágenes) — estado real, no supuesto. - Levantar el pipeline de scraping + Overpass API (Week 5-6). - Entrenar baseline del motor de valoración con datos históricos disponibles (Week 6). - Definir estrategia de validación del modelo de visión (supervisada vs. no supervisada). - Prototipo funcional con los tres modelos integrados (Week 10).