InmoScore · flujo de datos de extremo a extremo

Un solo comando reproduce todo desde `data/raw/`: `python code/run_pipeline.py` (con `--acquire` descarga antes las fuentes). Cada paso escribe en `data/processed/` y no modifica sus entradas.

PASO 01

Adquisición

ENTRADAS

- 9 fuentes públicas: Urbania, SAT, BCRP, SIDPOL, OSM, INEI, MIVIVIENDA

REGLAS

- descarga solo lo que falta
- robots.txt, límite de frecuencia, sin autenticación

data/raw/ (no versionado) · 9 archivos, 62 337 filas de Alcabala

→

PASO 02

Feature store

OPERACIONES

- filtro IQR de precio/m² por distrito: 3 987 → 3 896
- índice de criminalidad por 1 000 hab.
- POIs asignados a polígonos distritales
- join BCRP y MIVIVIENDA; marca `data_partial`

listings_eda.csv 3 896 × 30 · manifiesto SHA-256 · duplicados reportados

→

PASO 03

Análisis exploratorio

OPERACIONES

- resumen numérico y asimetría
- correlaciones de Spearman
- cobertura y dispersión por distrito
- relación entorno–precio

eda_*.csv + 4 figuras

→

PASO 04

Calibración Alcabala

OPERACIONES

- 24 148 compraventas al 100 %
- mediana de vivienda: operaciones ≥ S/ 80 000
- brecha oferta/cierre en 20 distritos

alcabala_calibration.csv · brecha +9 % a +14 % en distritos homogéneos

PASO 05

Motor de valoración

OPERACIONES

- 5 modelos, validación rotada de 5 pliegues
- regla de aceptación de Week 6
- intervalo del 80 % cross-conformal

listings_scored.csv (predicción fuera de pliegue) · **valuation_model.joblib** · MAE −17 %

→

PASO 06

Geocodificación

OPERACIONES

- 200 avisos de los 5 distritos con más oferta
- limpieza de dirección, 3 intentos, caché
- validación de distrito; sin imputar
- distancias Haversine a POIs

listings_poi_distances.csv · 166 avisos validados (83 %)

→

PASO 07

Score de constructora

OPERACIONES

- volumen de proyectos y unidades por promotor
- declarado parcial: sin plazos, sanciones ni antigüedad

builder_score_partial.csv · 453 promotores

→

PASO 08

Recomendación

OPERACIONES

- filtro de asequibilidad por perfil
- score ponderado sobre componentes disponibles
- explicación y marca de dato parcial
- verificación de criterios de aceptación

recommendations_demo.csv · **prototype/data.js**

Azul: ingesta · naranja: procesamiento y modelos · verde: servicio al usuario. Las figuras quedan en `figures/`; el diccionario de todas las columnas en `data_dictionary.csv`.