DELIVERY 1 · DS3022 DESARROLLO DE PRODUCTO DE DATOS

InmoScore

Cuánto vale de verdad cada aviso, y cuáles convienen a tu perfil, con la razón a la vista.

Denzel Cloud & DevOps · **Jyns** Machine Learning · **Lisseth** Data Analyst · **Mafer** Full-Stack & UX/UI

UTEC · Prof. Germain Garcia-Zanabria · 23 de setiembre de 2026 · github.com/Jyns123/DPD

PROBLEMA REVISADO

Comprar vivienda con información incompleta

- **¿El precio es razonable?** Los portales muestran precio y fotos, no un valor de referencia.
- **¿Cómo es el entorno?** Seguridad, colegios y transporte no están en el aviso.
- **¿Quién construye?** En planos, se paga por adelantado sin historial del promotor.

Enunciado: el comprador no tiene una forma accesible de saber si el precio de un aviso es razonable para sus características y su zona, ni de comparar avisos según sus propias prioridades.

3,4×

variación del precio por m² entre distritos (S/ 2 773 a S/ 9 299)

15 %

error mediano de usar la mediana del distrito como precio de referencia

+9–14 %

precio pedido sobre el de cierre (Alcabala) en los distritos comparables

USUARIOS

Dos compradores, dos rankings

María

Familia con una hija en edad escolar · ≥ 3 dormitorios

Ingreso S/ 15 000 · ahorro S/ 150 000 · presupuesto S/ 700 000

Precio 20 · Seguridad 40 · Colegios 30 · Constructora 10

Precio máximo alcanzable

S/ 662 959

Carlos

Primer comprador, prioriza el precio · ≥ 2 dormitorios

Ingreso S/ 9 000 · ahorro S/ 60 000 · presupuesto S/ 400 000

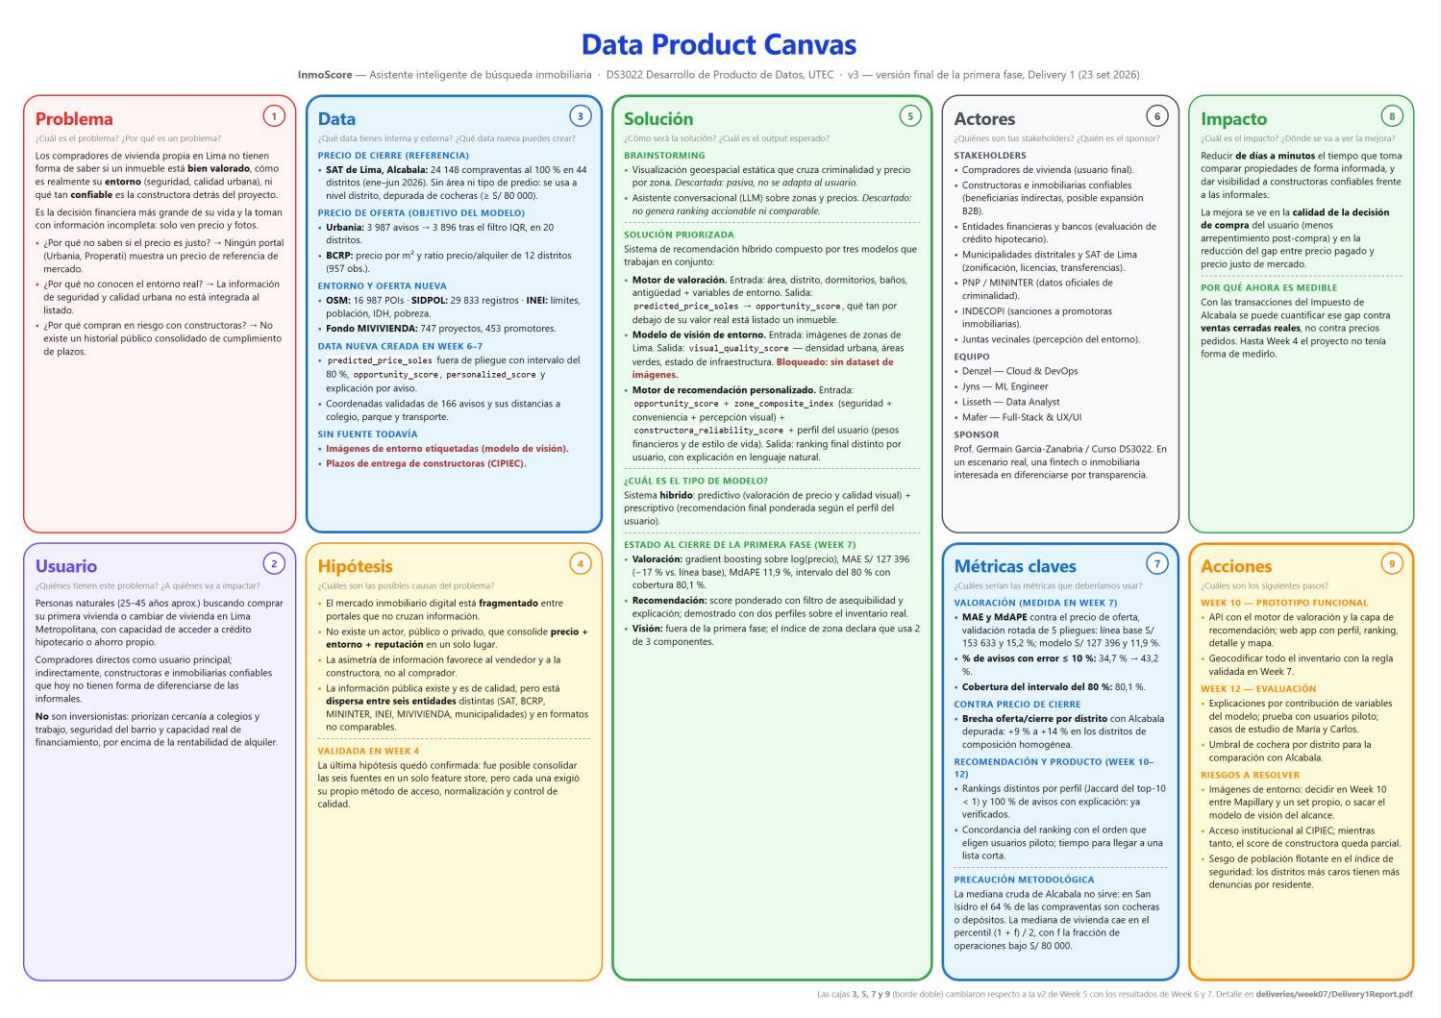
Precio 60 · Seguridad 15 · Colegios 20 · Constructora 5

Precio máximo alcanzable

S/ 367 775

Precio máximo = mínimo entre el presupuesto, el ahorro / 10 % de inicial y el crédito con cuota ≤ 30 % del ingreso (TEA 9 %, 20 años) más el ahorro. En ambos perfiles manda la cuota.

Canvas final de la primera fase



Data Product Canvas

InmoScore — Asistente inteligente de búsqueda inmobiliaria · DS3022 Desarrollo de Producto de Datos, UTEC · v3 — versión final de la primera fase, Delivery 1 (23 set 2026)

1 Problema

¿Cuál es el problema? ¿Por qué es un problema?

Los compradores de vivienda propia en Lima no tienen forma de saber si un inmueble está **bien valorado**, cómo es realmente su **entorno** (seguridad, calidad urbana), ni qué tan **confiable** es la constructora detrás del proyecto.

Es la decisión financiera más grande de su vida y la toman con información incompleta: solo ven precio y fotos.

- ¿Por qué no saben si el precio es justo? → Ningún portal (Urbania, Properati) muestra un precio de referencia de mercado.
- ¿Por qué no conocen el entorno real? → La información de seguridad y calidad urbana no está integrada al listado.
- ¿Por qué compran en riesgo con constructoras? → No existe un historial público consolidado de cumplimiento de plazos.

2 Usuario

¿Quiénes tienen este problema? ¿A quiénes va a impactar?

Personas naturales (25–45 años aprox.) buscando comprar su primera vivienda o cambiar de vivienda en Lima Metropolitana, con capacidad de acceder a crédito hipotecario o ahorro propio.

Compradores directos como usuario principal; indirectamente, constructoras e inmobiliarias confiables que hoy no tienen forma de diferenciarse de las informales.

No son inversionistas: priorizan cercanía a colegios y trabajo, seguridad del barrio y capacidad real de financiamiento, por encima de la rentabilidad de alquiler.

3 Data

¿Qué data tienes interna y externa? ¿Qué data nueva puedes crear?

PRECIO DE CIERRE (REFERENCIA)

- **SAT de Lima, Alcabala:** 24 148 compraventas al 100 % en 44 distritos (ene–jun 2026). Sin área ni tipo de predio: se usa a nivel distrito, depurada de cocheras (≥ S/ 80 000).

PRECIO DE OFERTA (OBJETIVO DEL MODELO)

- **Urbania:** 3 987 avisos → 3 896 tras el filtro IQR, en 20 distritos.
- **BCRP:** precio por m^2 y ratio precio/alquiler de 12 distritos (957 obs.).

ENTORNO Y OFERTA NUEVA

- **OSM:** 16 987 POIs · **SIDPOL:** 29 833 registros · **INEI:** límites, población, IDH, pobreza.
- **Fondo MIVIVIENDA:** 747 proyectos, 453 promotores.

DATA NUEVA CREADA EN WEEK 6–7

- `predicted_price_soles` fuera de pliegue con intervalo del 80 %, `opportunity_score`, `personalized_score` y explicación por aviso.
- Coordenadas validadas de 166 avisos y sus distancias a colegio, parque y transporte.

SIN FUENTE TODAVÍA

- **Imágenes de entorno etiquetadas (modelo de visión).**
- **Plazos de entrega de constructoras (CIPIEC).**

4 Hipótesis

¿Cuáles son las posibles causas del problema?

- El mercado inmobiliario digital está **fragmentado** entre portales que no cruzan información.
- No existe un actor, público o privado, que consolide **precio + entorno + reputación** en un solo lugar.
- La asimetría de información favorece al vendedor y a la constructora, no al comprador.
- La información pública existe y es de calidad, pero está **dispersa entre seis entidades** distintas (SAT, BCRP, MININTER, INEI, MIVIVIENDA, municipalidades) y en formatos no comparables.

VALIDADA EN WEEK 4

La última hipótesis quedó confirmada: fue posible consolidar las seis fuentes en un solo feature store, pero cada una exigió su propio método de acceso, normalización y control de calidad.

5 Solución

¿Cómo será la solución? ¿Cuál es el output esperado?

BRAINSTORMING

- Visualización geoespacial estática que cruza criminalidad y precio por zona. *Descartada: pasiva, no se adapta al usuario.*
- Asistente conversacional (LLM) sobre zonas y precios. *Descartado: no genera ranking accionable ni comparable.*

SOLUCIÓN PRIORIZADA

Sistema de recomendación híbrido compuesto por tres modelos que trabajan en conjunto:

- **Motor de valoración.** Entrada: área, distrito, dormitorios, baños, antigüedad + variables de entorno. Salida: `predicted_price_soles` → `opportunity_score`, qué tan por debajo de su valor real está listado un inmueble.
- **Modelo de visión de entorno.** Entrada: imágenes de zonas de Lima. Salida: `visual_quality_score` — densidad urbana, áreas verdes, estado de infraestructura. **Bloqueado: sin dataset de imágenes.**
- **Motor de recomendación personalizado.** Entrada: `opportunity_score` + `zone_composite_index` (seguridad + conveniencia + percepción visual) + `constructora_reliability_score` + perfil del usuario (pesos financieros y de estilo de vida). Salida: ranking final distinto por usuario, con explicación en lenguaje natural.

¿CUÁL ES EL TIPO DE MODELO?

Sistema **híbrido**: predictivo (valoración de precio y calidad visual) + prescriptivo (recomendación final ponderada según el perfil del usuario).

ESTADO AL CIERRE DE LA PRIMERA FASE (WEEK 7)

- **Valoración:** gradient boosting sobre log(precio), MAE S/ 127 396 (−17 % vs. línea base), MdAPE 11,9 %, intervalo del 80 % con cobertura 80,1 %.
- **Recomendación:** score ponderado con filtro de asequibilidad y explicación; demostrado con dos perfiles sobre el inventario real.
- **Visión:** fuera de la primera fase; el índice de zona declara que usa 2 de 3 componentes.

6 Actores

¿Quiénes son tus stakeholders? ¿Quién es el sponsor?

STAKEHOLDERS

- Compradores de vivienda (usuario final).
- Constructoras e inmobiliarias confiables (beneficiarias indirectas, posible expansión B2B).
- Entidades financieras y bancos (evaluación de crédito hipotecario).
- Municipalidades distritales y SAT de Lima (zonificación, licencias, transferencias).
- PNP / MININTER (datos oficiales de criminalidad).
- INDECOPI (sanciones a promotoras inmobiliarias).
- Juntas vecinales (percepción del entorno).

EQUIPO

- Denzel — Cloud & DevOps
- Jyns — ML Engineer
- Lisseth — Data Analyst
- Mafer — Full-Stack & UX/UI

SPONSOR

Prof. Germain Garcia-Zanabria / Curso DS3022. En un escenario real, una fintech o inmobiliaria interesada en diferenciarse por transparencia.

7 Métricas claves

¿Cuáles serían las métricas que deberíamos usar?

VALORACIÓN (MEDIDA EN WEEK 7)

- **MAE y MdAPE** contra el precio de oferta, validación rotada de 5 pliegues: línea base S/ 153 633 y 15,2 %; modelo S/ 127 396 y 11,9 %.
- **% de avisos con error ≤ 10 %:** 34,7 % → 43,2 %.
- **Cobertura del intervalo del 80 %:** 80,1 %.

CONTRA PRECIO DE CIERRE

- **Brecha oferta/cierre por distrito** con Alcabala depurada: +9 % a +14 % en los distritos de composición homogénea.

RECOMENDACIÓN Y PRODUCTO (WEEK 10–12)

- Rankings distintos por perfil (Jaccard del top-10 < 1) y 100 % de avisos con explicación: ya verificados.
- Concordancia del ranking con el orden que eligen usuarios piloto; tiempo para llegar a una lista corta.

PRECAUCIÓN METODOLÓGICA

La mediana cruda de Alcabala no sirve: en San Isidro el 64 % de las compraventas son cocheras o depósitos. La mediana de vivienda cae en el percentil (1 + f) / 2, con f la fracción de operaciones bajo S/ 80 000.

8 Impacto

¿Cuál es el impacto? ¿Dónde se va a ver la mejora?

Reducir **de días a minutos** el tiempo que toma comparar propiedades de forma informada, y dar visibilidad a constructoras confiables frente a las informales.

La mejora se ve en la **calidad de la decisión de compra** del usuario (menos arrepentimiento post-compra) y en la reducción del gap entre precio pagado y precio justo de mercado.

POR QUÉ AHORA ES MEDIBLE

Con las transacciones del Impuesto de Alcabala se puede cuantificar ese gap contra **ventas cerradas reales**, no contra precios pedidos. Hasta Week 4 el proyecto no tenía forma de medirlo.

9 Acciones

¿Cuáles son los siguientes pasos?

WEEK 10 — PROTOTIPO FUNCIONAL

- API con el motor de valoración y la capa de recomendación; web app con perfil, ranking, detalle y mapa.
- Geocodificar todo el inventario con la regla validada en Week 7.

WEEK 12 — EVALUACIÓN

- Explicaciones por contribución de variables del modelo; prueba con usuarios piloto; casos de estudio de María y Carlos.
- Umbral de cochera por distrito para la comparación con Alcabala.

RIESGOS A RESOLVER

- Imágenes de entorno: decidir en Week 10 entre Mapillary y un set propio, o sacar el modelo de visión del alcance.
- Acceso institucional al CIPIEC; mientras tanto, el score de constructora queda parcial.
- Sesgo de población flotante en el índice de seguridad: los distritos más caros tienen más denuncias por residente.

Las cajas **3, 5, 7 y 9** (borde doble) cambiaron respecto a la v2 de Week 5 con los resultados de Week 6 y 7. Detalle en **deliveries/week07/Delivery1Report.pdf**.

DATOS

Ocho fuentes públicas en un solo feature store

Urbania

3 987 avisos

SAT · Alcabala

24 148 compraventas

BCRP

957 observaciones

SIDPOL

29 833 registros

OpenStreetMap

16 987 POIs

INEI

51 distritos

Fondo MIVIVIENDA

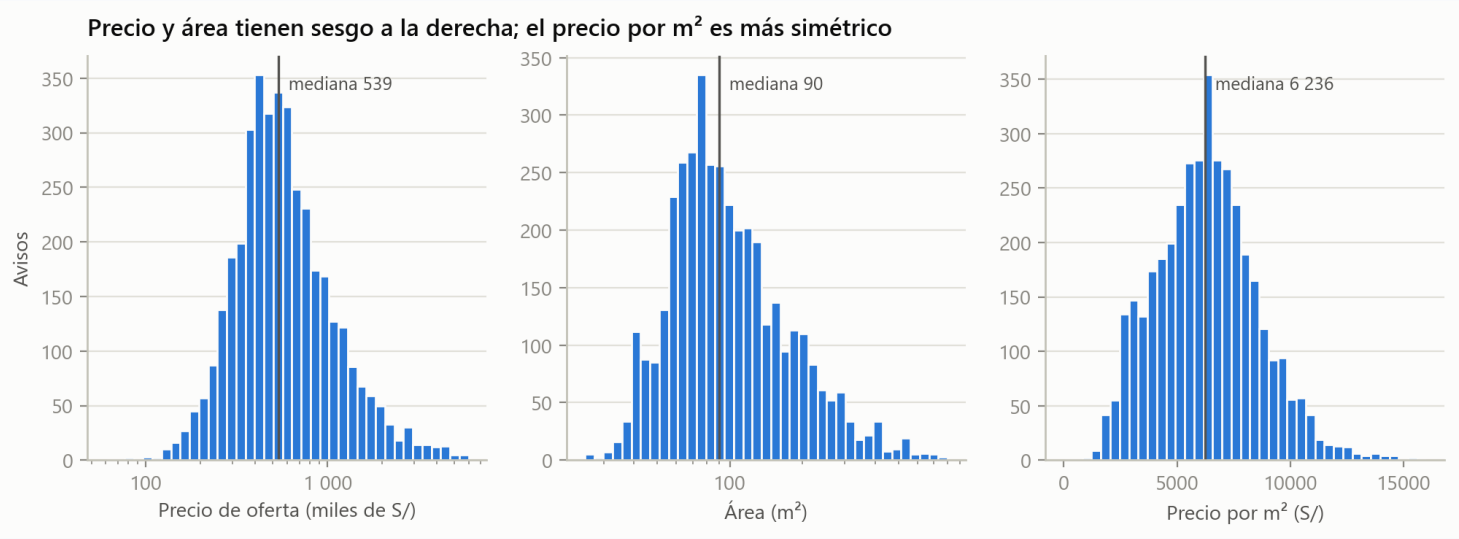
747 proyectos

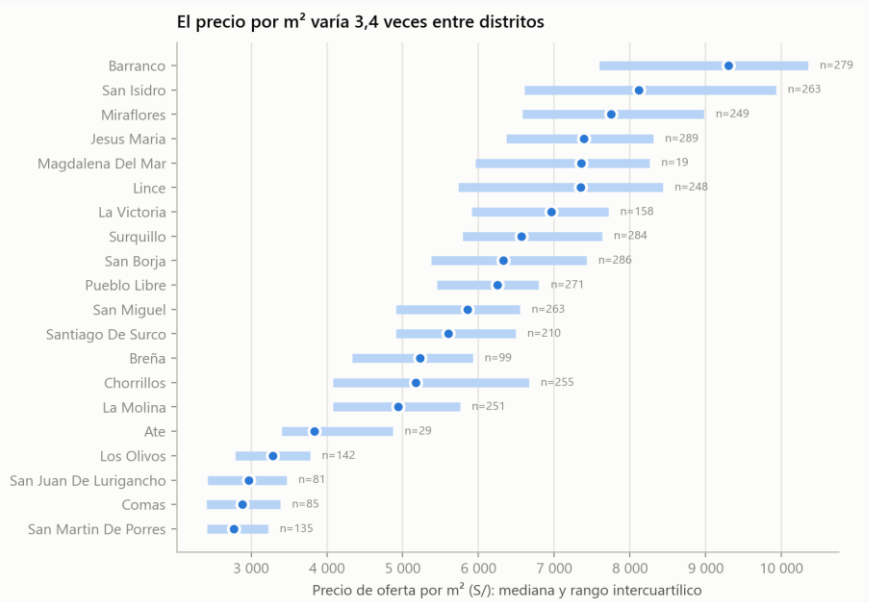
Nominatim

200 avisos geocodificados

- **Filtro IQR por distrito:** 3 987 → 3 896 avisos en 20 distritos.
- **Sin imputación:** data_partial marca 984 avisos (25,3 %) fuera de la cobertura del BCRP.
- **Corrección de Week 6:** el ratio precio/alquiler quedaba vacío por un join sin normalizar; data_partial salía en 100 %.
- **Trazabilidad:** manifiesto SHA-256 por archivo y diccionario de 315 columnas generado desde los datos.

El área explica el precio; el distrito, el precio por m²

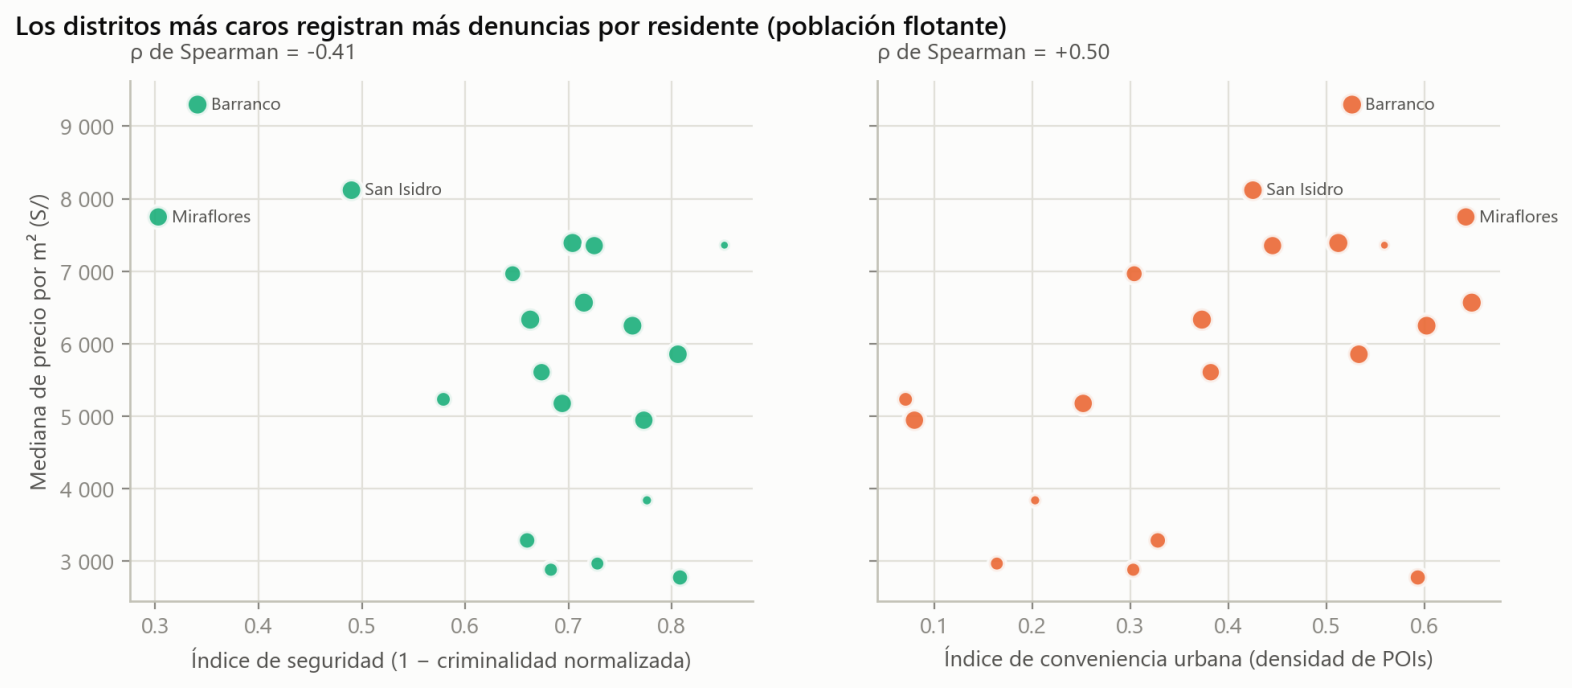




- **ρ(precio, área) = 0,74;** ρ(precio/m², área) = −0,21: el m² de los inmuebles grandes cuesta menos.
- **Asimetría:** precio 4,8, área 2,9, precio por m² 0,4 → modelar en logaritmos.
- **Dispersión dentro del distrito:** en Chorrillos la mitad central va de −21 % a +29 % de la mediana.

HALLAZGO

Los distritos más caros tienen más denuncias por residente



Miraflores, Barranco y San Isidro concentran comercio y turismo: las denuncias se dividen entre pocos residentes.

ρ = −0,41

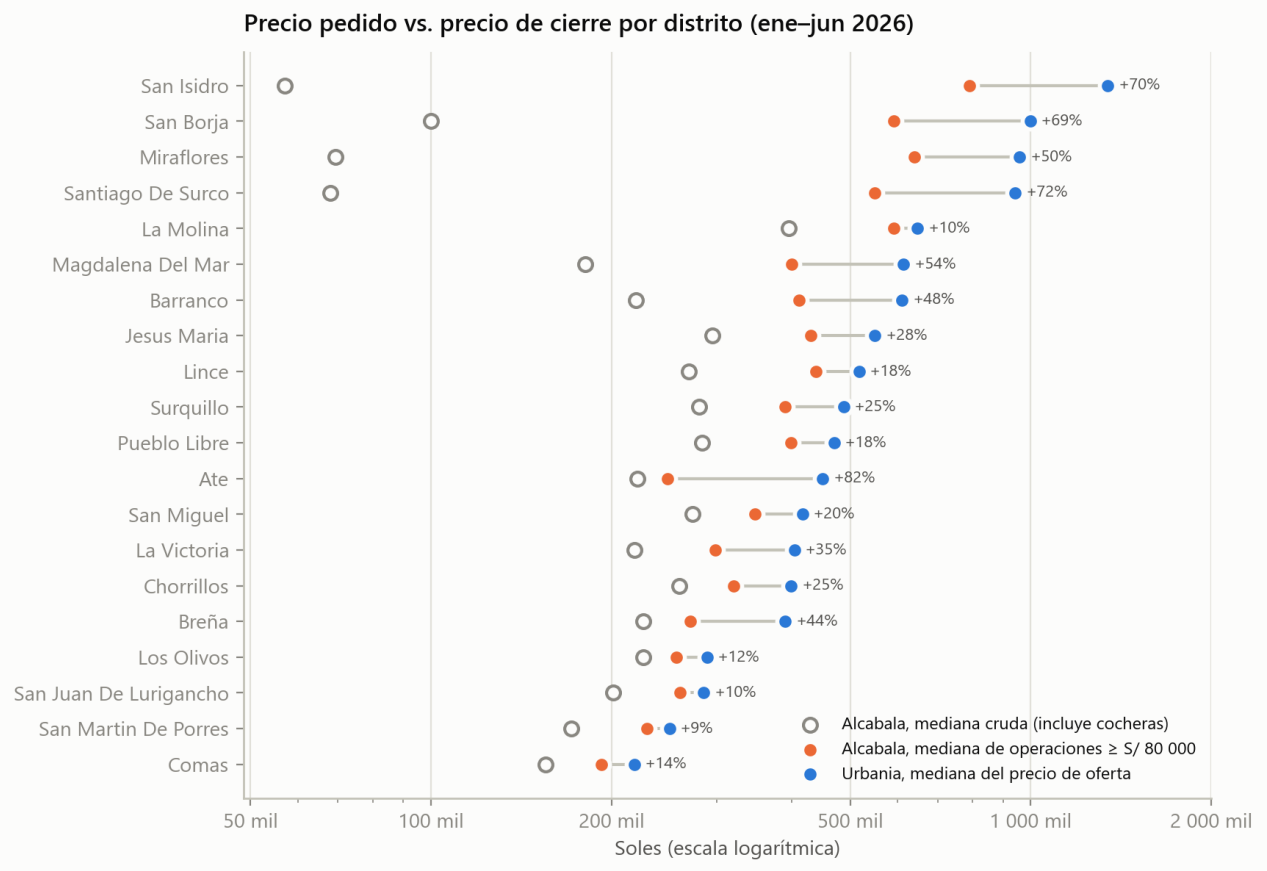
seguridad vs precio por m² en 20 distritos

ρ = +0,50

conveniencia urbana vs precio por m²

Acción: probar normalización por superficie y por modalidad de denuncia en Week 11.

Alcabala: cuánto se paga de verdad



- **24 148 compraventas** al 100 % en 44 distritos (ene–jun 2026).
- **Problema:** 64 % de las operaciones de San Isidro son cocheras o depósitos (< S/ 80 000).
- **Criterio:** la mediana de vivienda está en el percentil (1 + f) / 2 = mediana de las operaciones ≥ S/ 80 000.
- **Resultado:** la oferta supera al cierre en +9 % a +14 % donde la composición es comparable.
- **En distritos caros** la brecha (+50–72 %) mide composición, no negociación.

Gradient boosting: −17 % de error frente a la línea base

Modelo	MAE (S/)	MdAPE	Error ≤ 10 %	ΔMAE vs A
A · Mediana distrital × área	153 633	15,2 %	34,7 %	—
B · Log-lineal área + distrito	150 995	14,1 %	36,4 %	−1,7 %
C1 · Ridge de Week 6	166 668	14,8 %	35,6 %	+8,5 %
C2 · Ridge v2 (log-área)	136 257	13,6 %	38,2 %	−11,3 %
D · Gradient boosting	**127 396**	**11,9 %**	**43,2 %**	**−17,1 %**

11,9 %

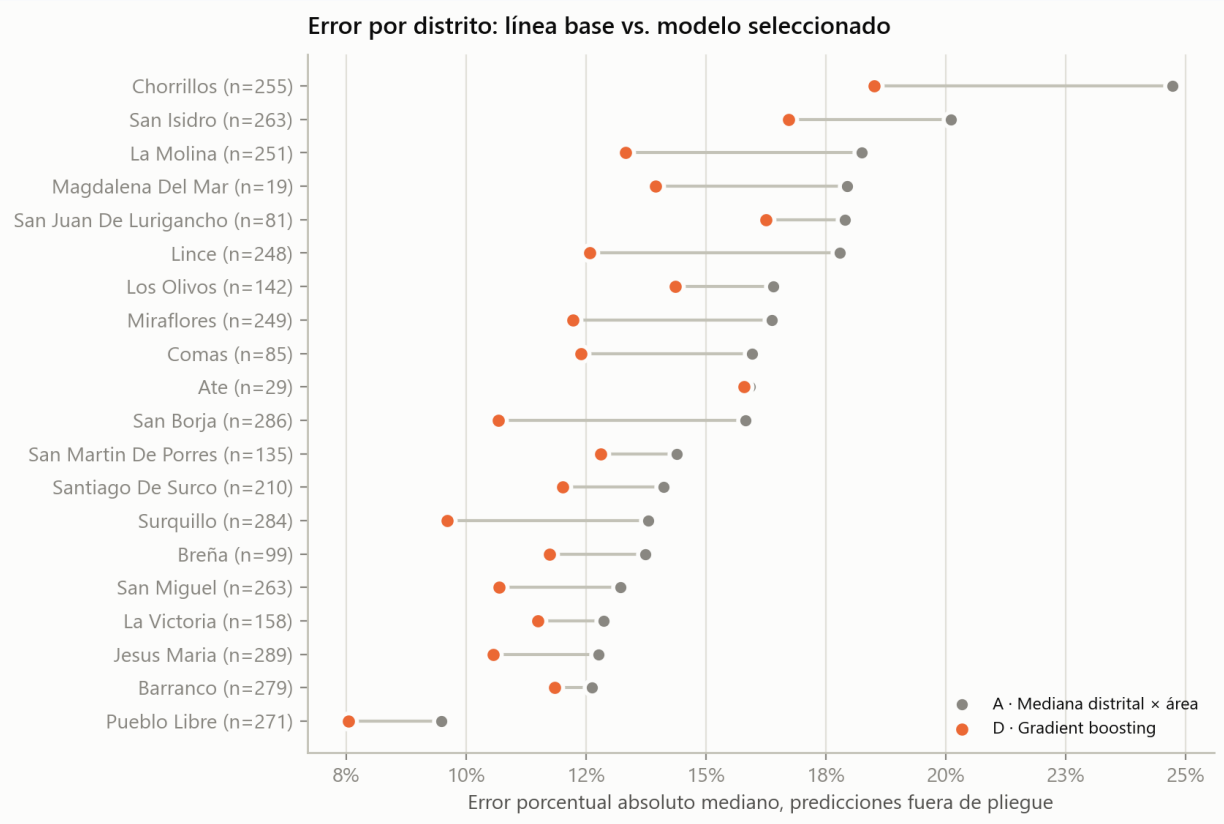
MdAPE del modelo (línea base 15,2 %)

80,1 %

cobertura del intervalo del 80 %

- **Reproducible:** el pliegue 0 da las cifras exactas de Week 6 (S/ 155 372,04 y S/ 155 396,37).
- **Error de especificación:** el Ridge de Week 6 usaba el área lineal para predecir log(precio): +8,5 % de error.
- **Selección automática** con la regla de Week 6; D mejora el MdAPE en los 20 distritos.

Mejora en todos los distritos, con incertidumbre honesta



- **Intervalo del 80 % cross-conformal:** cuantiles de los residuos fuera de pliegue; cobertura 80,1 % (antes 72 % con residuos de entrenamiento).
- **388 avisos (10 %)** quedan bajo el intervalo: pasan a una lista "por verificar".
- **Ate (29 avisos):** mejora marginal del MdAPE y +3 % de MAE; la regla de distritos chicos lo acepta (cociente 0,87).
- **Alternativa interpretable:** Ridge v2, a 7 % de D, si las explicaciones SHAP no resultan legibles.

Geocodificación: de 10 avisos a 200, con 83 % validados

Distrito	Avisos	Validados	Tasa
Jesus Maria	40	38	95 %
Surquillo	40	35	88 %
Barranco	40	33	82 %
San Borja	40	33	82 %
Pueblo Libre	40	27	68 %
Total	**200**	**166**	**83 %**

- **Limpieza:** departamento, "al 500", "cerca a…", abreviaturas Jr./Av./Psj.
- **Tres intentos:** dirección, calle sin número, urbanización (precisión "zona").
- **Validación sin imputar:** polígono ±300 m o distrito según OSM; 1,1 s por consulta con caché.
- **57 % → 83 %:** 31 falsos rechazos por el GeoJSON simplificado.
- **Distancia mediana:** colegio 158 m, parque 102 m, paradero 221 m.

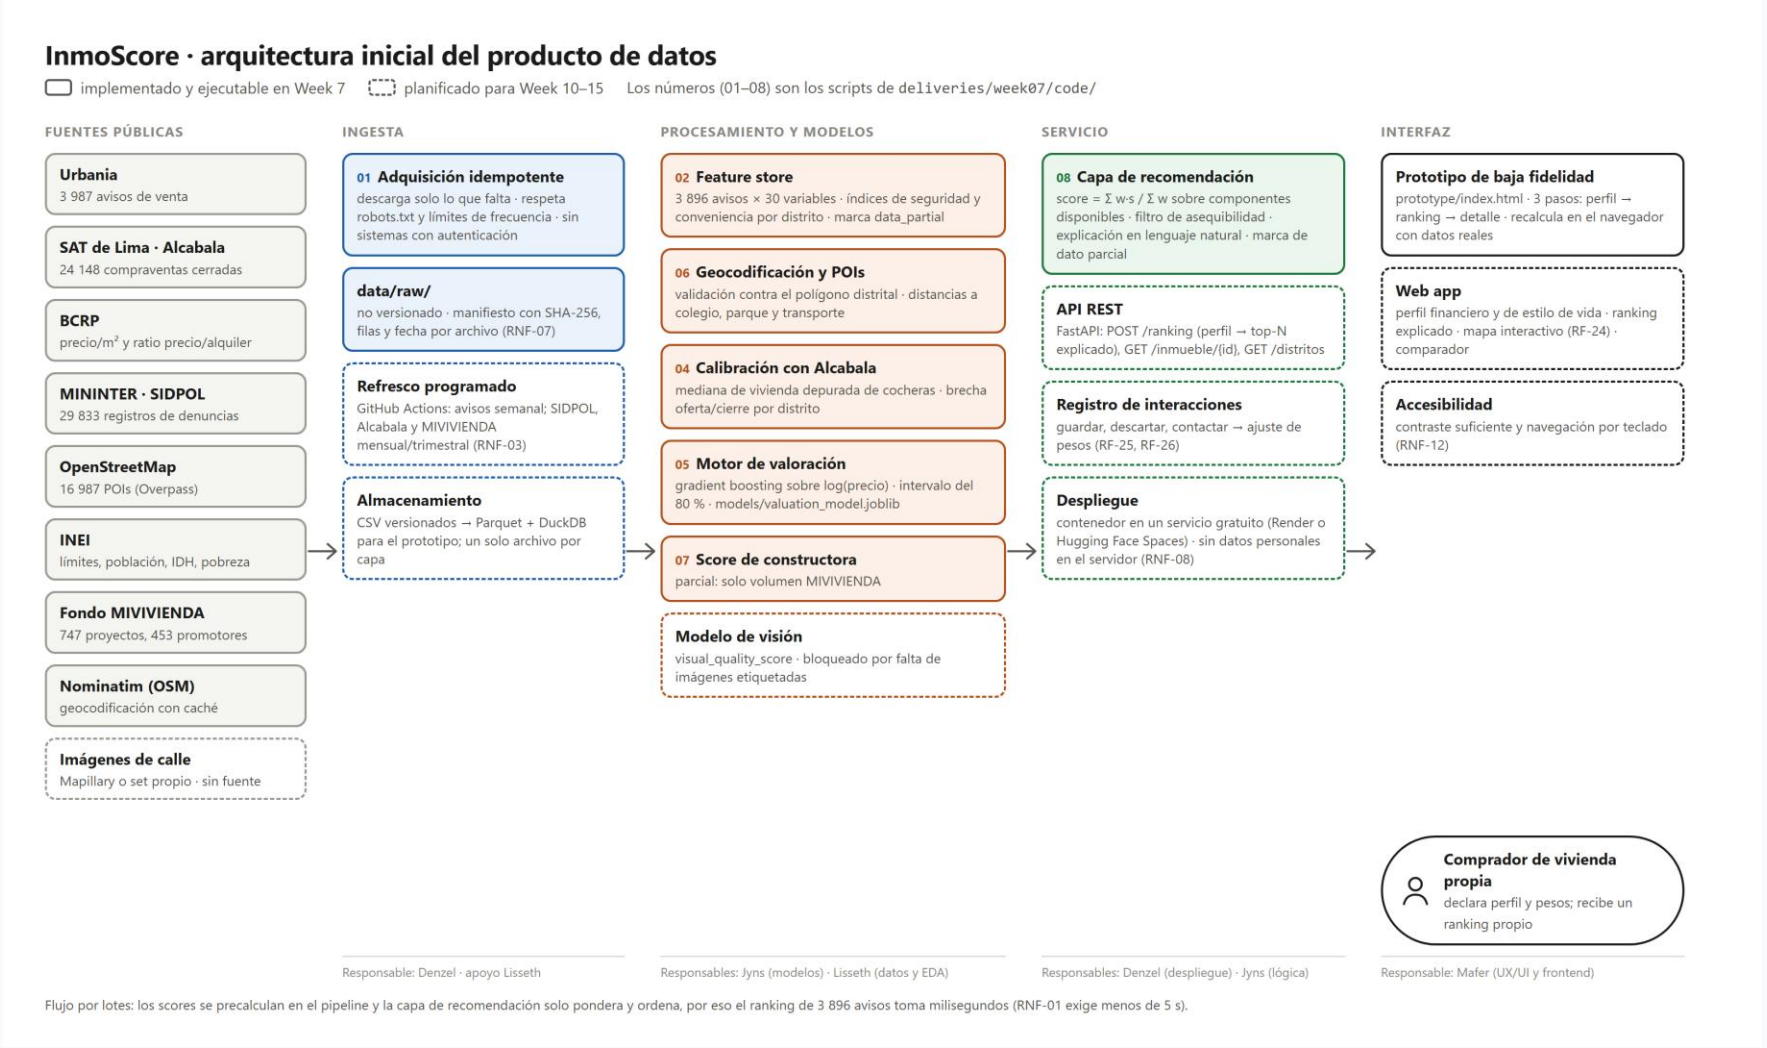
Un ranking por perfil, explicado y sin imputar

score = Σ peso × componente / Σ pesos de los componentes disponibles

- **Componentes:** precio (logística del opportunity score), seguridad, colegios y servicios, constructora.
- **Faltante ≠ cero:** sale del cálculo y la explicación lo declara.
- **Precio atípico** → lista "por verificar", no ranking.
- **Diversidad:** máximo 3 avisos por distrito en el top 10.
- **Iteración:** la v1 daba el mismo top 10 a ambos perfiles (Jaccard 1,0).

Criterio	Resultado
REQ-01 perfiles distintos (Jaccard top 10)	0,43 ✓
REQ-01 mismo presupuesto (Jaccard)	0,67 ✓
REQ-01 ρ de Spearman entre scores	0,69 ✓
REQ-02 avisos con explicación	100 % ✓
Atípicos en el ranking	0 % ✓
Parciales que lo declaran	100 % ✓
RNF-01 tiempo del ranking	0,09 s ✓

Por lotes: el pipeline precalcula, el servicio solo pondera



Flujo por lotes: los scores se precalculan en el pipeline y la capa de recomendación solo pondera y ordena, por eso el ranking de 3 896 avisos toma milisegundos (RNF-01 exige menos de 5 s).

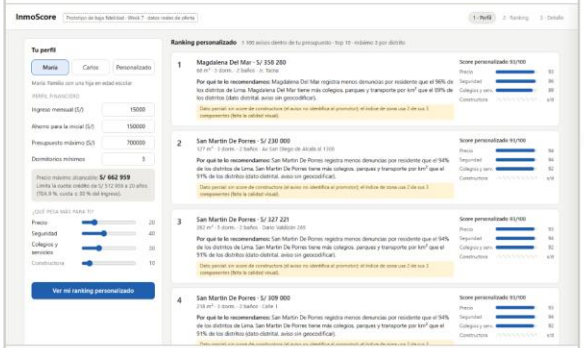
Prototipo de baja fidelidad con datos reales

InmoScore · flujo principal del usuario en tres pasos

Capturas del prototipo de baja fidelidad (`prototype/index.html`) con datos reales. RNF-04 pide llegar al ranking en menos de tres pasos; aquí basta con elegir o ajustar el perfil.

PASO 1

Declarar el perfil



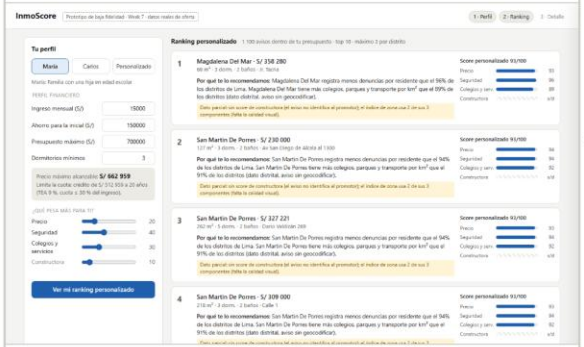
Ingreso, ahorro para la inicial, presupuesto y dormitorios; pesos de precio, seguridad, colegios y constructora.

- Calcula el precio máximo alcanzable y dice qué lo limita: presupuesto, inicial o cuota.

RF-19 · RF-20 · REQ-08 · RNF-08

PASO 2

Recibir el ranking explicado



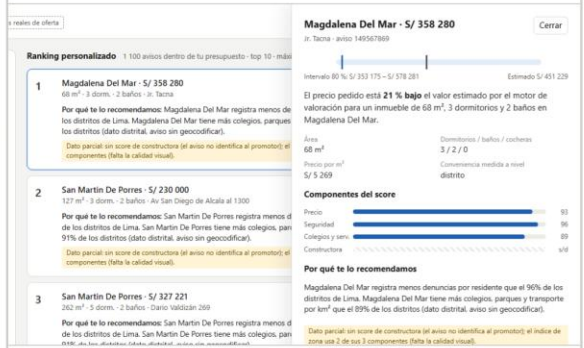
Top 10 dentro del presupuesto, con máximo 3 avisos por distrito; se recalcula al mover un peso.

- Cada tarjeta trae su explicación y las barras de cada componente del score.

RF-21 · RF-22 · REQ-01 · REQ-02 · RNF-01

PASO 3

Revisar el detalle



Precio pedido frente al valor estimado y su intervalo del 80 %, componentes y explicación completa.

- Aclara que la estimación se basa en precios de oferta, no de cierre.

RF-13 · RF-14 · RF-23 · RNF-05

Flujo alternativo · dato parcial

Si falta un componente con peso (constructora, calidad visual), el aviso no se omite ni se imputa: la tarjeta lo declara en un recuadro amarillo (RF-23, RNF-06).

Flujo alternativo · precio atípico

Si el precio queda bajo el intervalo del 80 %, el aviso sale del ranking y aparece en "Por verificar": puede ser una ganga o un error de área.

Pendiente para Week 10–12

Mapa interactivo (RF-24), guardar, descartar y comparar (RF-25) y ajuste de pesos con el feedback implícito (RF-26).

REQUERIMIENTOS

Estado al cierre de la primera fase

11

de 26 funcionales implementados y verificados

10

funcionales parciales, con plan y semana

7

de 13 no funcionales cumplidos

1

bloqueado por datos: modelo de visión

Criterio de aceptación (Week 5)	Estado
≥ 500 avisos con < 10 % de faltantes críticos	✓ 3 896 avisos, 0 faltantes
MAE comparado contra la línea base	✓ −17,1 %
Dos perfiles, dos rankings	✓ Jaccard 0,43
Explicación en cada recomendación	✓ 100 %
Modelo de visión ≥ 70 %	Sin datos: decisión en Week 10
Prototipo desplegado	Local hoy; URL en Week 10

Prioridades y responsables

W8
Parcial
retroalimentación y stack

W9
Construir
geocodificación completa, API, web app

W10
Prototipo funcional
flujo desplegado, mapa, decisión de visión

W11
Evaluar
SHAP, umbral Alcabala, seguridad, usuarios

W12
Evaluación
casos de estudio, guardar y comparar

W13–14
Cerrar
refresco, accesibilidad, reporte y video

W15
Delivery 2
presentación final

Integrante	Responsabilidad principal hasta Week 15
Denzel · Cloud & DevOps	Contenedor y despliegue, GitHub Actions, geocodificación completa, URL pública
Jyns · Machine Learning	Valoración y evaluación, recomendación, explicaciones SHAP, decisión de visión
Lisseth · Data Analyst	Calidad del pipeline, POIs, diccionario, umbral Alcabala, índice de seguridad
Mafer · Full-Stack & UX/UI	Web app y mapa, alta fidelidad, prueba con usuarios, página y video

PRÓXIMOS PASOS Y RIESGOS

Lo que falta decidir antes de Week 10

Imágenes de entorno

Mapillary más un set propio, o sacar el modelo de visión del alcance y declararlo.

Sesgo en seguridad

Normalizar por superficie o por modalidad; declararlo en la interfaz.

Cierre vs oferta

Umbral de cochera por distrito con la relación valor/autovalúo de Alcabala.

Inventario vigente

Complementar el dataset sin fecha con el scraper por sitemap de Week 6.

Gracias · preguntas